---
title: "Quantium Virtual Internship - Retail Strategy and Analytics - Task 1"
mainfont: Roboto
monofont: Consolas
output:
 pdf_document:
 df_print: default
 highlight: tango
 keep_tex: yes
 latex_engine: xelatex
header-includes:
 \usepackage{fvextra}

Bibliotecas e datasets utilizados:

```{r}
library(data.table)
library(ggplot2)
library(stringr)

#transactionData <- QVI_transaction_data.xlsx
#customerData <- QVI_purchase_behaviour.csv
transactionData <- as.data.table(transactionData)
customerData <- as.data.table(customerData)
```

Primeiramente queremos entender os dados que iremos trabalhar. Vamos explorar os dois datasets fornecidos e fazer a limpeza de dados se necessário.

Customer Data
```{r Examinar os dados dos clientes}

str(customerData)
head(customerData)

```
Neste dataset temos os dados dos clientes, onde cada clente tem um número de cartão de lealdade, e categorias como estágio de vida e cliente premium.

Transaction data
```{r Examinar os dados de transação}
str(transactionData)
head(transactionData)
```
Neste dataset temos dados de transações feitas em um ano.

Como a coluna DATE está em formato numérico, precisamos converter a coluna para formato em data.
```{r Conversão Date para formato em data}
transactionData$DATE <- as.Date(transactionData$DATE, origin = "1899-12-30")
```

Vamos verficar se todos os produtos comprados são realmente chips examinando a coluna PROD_NAME.

```{r Resumo da coluna PROD_NAME}

table(transactionData$PROD_NAME)

```

```{r}
productWords <- data.table(unlist(strsplit(unique(transactionData$PROD_NAME)," ")))
setnames(productWords,'words')

```

Removeremos dígitos e carcteres especiais.

```{r Filtrar somente letras no productWords}

productWords <- productWords[grepl("^[a-zA-Z]+$", words)]


```

Tabela de frequencias das palavras.

```{r}
freq_palavras <- productWords[, .N, by = words][order(-N)]
```

Queremos remover produtos que não são chips, como salsa.

```{r}
transactionData[, SALSA := grepl("salsa", tolower(PROD_NAME))]
transactionData <- transactionData[SALSA == FALSE, ][, SALSA := NULL]
```

Sumario da tabela transactionData. Queremos verificar possíveis valores nulos e outliers.

```{r}
summary(transactionData)
```

Não temos valores nulos, porem, o PROD_QTY aparenta ter outliers(max 200 pacotes vendidos). Vamos verificar:

```{r}
transactionData[PROD_QTY == 200]
```

Encontramos duas transações de 200 pacotes, de um mesmo cliente(LYLTY_CARD_NBR = 226000). Vamos Verificar se este cliente fez mais transações além dessas duas.

```{r}
transactionData[LYLTY_CARD_NBR == 226000]
```

Parece que este cliente tem somente duas transações durante o ano e não é um cliente ordinário. Vamos remover este cliente para futuras análises.

```{r}
transactionData <- transactionData[LYLTY_CARD_NBR != 226000]

```

```{r}
summary(transactionData)
```

Contaremos o número de transações por dia para verificar se temos prolemas nos dados.

```{r}
transacoes_por_dia <- transactionData[, .N, by = DATE]
summary(transacoes_por_dia)
```

Percebemos que os dados são coletados de 01/07/2018 até 30/06/2019, porém temos 364 observações em transacoes_por_dia. Possivelmente temos uma data faltando.

Vamos criar uma tabela com todas as datas de 01/07/2018 até 30/06/2019 e comparar com o nossos dados para encontrar a data faltando.

```{r}
todas_datas <- data.table(
```

```
  DATE = seq(as.Date("2018-07-01"), as.Date("2019-06-30"), by = "day")
)

calendario_completo <- merge(todas_datas, transacoes_por_dia, by = "DATE", all.x =
TRUE)
```

Encontramos a data faltante, dia 25/12/2018.

```{r fig.align = "center"}
theme_set(theme_bw())
theme_update(plot.title = element_text(hjust = 0.5))

ggplot(transacoes_por_dia, aes(x = DATE, y = N)) +
 geom_line() +
 labs(x = "Dia", y = "Número de transações", title = "Transações por dia") +
 scale_x_date(breaks = "1 month") +
 theme(axis.text.x = element_text(angle = 90, vjust = 0.5))
```

Vamos dar um zoom no mês de dezembro, onde há um crescimento nas vendas.

```{r}
mes_dezembro <- transacoes_por_dia[month(DATE) == 12]

theme_set(theme_bw())
theme_update(plot.title = element_text(hjust = 0.5))

ggplot(mes_dezembro, aes(x = DATE, y = N)) +
 geom_line() +
 labs(x = "Dia", y = "Número de transações", title = "Transações por dia em dezembro")
+
 scale_x_date(breaks = "1 day") +
 theme(axis.text.x = element_text(angle = 90, vjust = 0.5))
```

Percebemos que há um aumento de venda de chips nos dias anteriores ao Natal, porém no dia exato do Natal(25/12/2018) não há vendas, pois as lojas fecham no Natal.

Agora que os dados não tem mais outliers, vamos criar novas características como tamanho do pacote ou marca dos chips pela coluna PROD_NAME.

```{r}
transactionData[, PACK_SIZE := parse_number(PROD_NAME)]

transactionData[, .N, PACK_SIZE][order(PACK_SIZE)]
```

Temos então pacotes de 70g até 380g, o que parece sensato.

Vamos fazer um histograma de PACK_SIZE

```{r}
packsizeN <- transactionData[, .N, PACK_SIZE]

ggplot(packsizeN, aes(x = factor(PACK_SIZE), y = N)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  labs(title = "Distribuição por Tamanho de Embalagem",
       x = "Tamanho da Embalagem (g)",
       y = "Número de Ocorrências") +
  theme_minimal()

```
Vamos adicionar também na tabela transactionData a característica marca do produto BRAND.
```{r}
transactionData[, BRAND := word(PROD_NAME, 1)]

transactionData[, .N, BRAND][order(BRAND)]
```

```
Obtemos 28 tipos de marca de chips, o que parece sensato.
Temos algumas marcas que parecem ser o mesmo, então vamos combinar estes juntos.
(Red/RRD, Dorito/Doritos, Grain/GrnWves, Infuzions/Infzns, Smith/Smiths,
Snbts/Sunbites, WW/Woolworths)
```{r}
transactionData[BRAND == "Red", BRAND := "RRD"]
transactionData[BRAND == "Dorito", BRAND := "Doritos"]
transactionData[BRAND == "GrnWves", BRAND := "Grain"]
transactionData[BRAND == "Infzns", BRAND := "Infuzions"]
transactionData[BRAND == "Smith", BRAND := "Smiths"]
transactionData[BRAND == "Snbts", BRAND := "Sunbites"]
transactionData[BRAND == "WW", BRAND := "Woolworths"]

```
Temos então 21 tipos de marca de chips.

Vamos agora observar o dataset dos clientes, customerData.
```{r}
summary(customerData)
```
Vamos fazer o histograma de LIFESTAGE e PREMIUM_CUSTOMER
```{r}
LifeN <- customerData[, .N, LIFESTAGE]

ggplot(LifeN, aes(x = N, y = reorder(LIFESTAGE, N))) +
  geom_bar(stat = "identity", fill = "steelblue") +
  labs(x = "Quantidade de Clientes", y = "Estágio de Vida")


PremCusN <- customerData[, .N, PREMIUM_CUSTOMER]

ggplot(PremCusN, aes(x = N, y = reorder(PREMIUM_CUSTOMER, N))) +
  geom_bar(stat = "identity", fill = "steelblue") +
  labs(x = "Quantidade de Clientes", y = "Tipos de Clientes")


```

Vamos criar uma tabela juntando os dados de clientes com transações
```{r}
data <- merge(transactionData, customerData, all.x = TRUE)
```
Como o número de linhas da tabela data é o mesmo da tabela transactioData, podemos
confirmar que nenhuma duplicata foi criada.

Vamos confirmar se não teve nenhum dado faltante(NULLs).
```{r}
summary(data)
```
Salvar o dataset data em csv
```{r}
caminho <- file.path("c:","Users", "renat", "Documents", "quantium", "quantium_chips")
fwrite(data, paste0(caminho, "QVI_data.csv"))
```


Parte de analise de dados

Total de vendas por estágio de vida(LIFE_STAGE) e clientes Premium(PREMIUM_CUSTOMER)
```{r}
totVendasLife <- data[,.(Valor = sum(TOT_SALES)),by = LIFESTAGE]
totVendasPrem <- data[,.(Valor = sum(TOT_SALES)),by = PREMIUM_CUSTOMER]
totVendasLiPr <- data[,.(Valor = sum(TOT_SALES)),by = .(LIFESTAGE, PREMIUM_CUSTOMER)]


ggplot(totVendasLife, aes(x = Valor, y = reorder(LIFESTAGE, Valor))) +
  geom_bar(stat = "identity", fill = "pink") +
```
```

```
  labs(title = "Total de Vendas por Estágio de Vida" ,x = "Valor Total", y = "Estágio
da Vida")

ggplot(totVendasPrem, aes(x = Valor, y = reorder(PREMIUM_CUSTOMER, Valor))) +
  geom_bar(stat = "identity", fill = "pink" ) +
  labs(title = "Total de Vendas por Tipo de Clientes", x = "Valor Total", y = "Tipo de
Cliente")

ggplot(totVendasLiPr, aes(x = Valor, y = reorder(LIFESTAGE, Valor), fill =
PREMIUM_CUSTOMER)) +
  geom_bar(stat = "identity", position = "dodge") +
  labs(title = "Total de Vendas por Segmento",
      x = "Valor Total", y = "Estágio de Vida", fill = "Tipo de Cliente") +
  theme_minimal()
```

Número de clientes por Lifestage e Premium_Customer

```{r}
LifePremN <- data[, .(N = uniqueN(LYLTY_CARD_NBR)), by = .(LIFESTAGE,
PREMIUM_CUSTOMER)]

ggplot(LifePremN, aes(x = N, y = reorder(LIFESTAGE, N), fill = PREMIUM_CUSTOMER)) +
  geom_bar(stat = "identity", position = "dodge") +
  labs(title = "Total de Clientes por Segmento",
      x = " ", y = "Estágio de Vida", fill = "Tipo de Cliente") +
  theme_minimal()
```

Média de número de produtos comprados por clientes, por LIFESTAGE e PREMIUM_CUSTOMER

```{r}
LiPrMean <- data[, .(Media = mean(PROD_QTY)), by = .(LIFESTAGE, PREMIUM_CUSTOMER)]

ggplot(LiPrMean, aes(x = Media, y = reorder(LIFESTAGE, Media), fill =
PREMIUM_CUSTOMER)) +
  geom_bar(stat = "identity", position = "dodge") +
  labs(title = "Média de Produtos comprados por Segmento",
      x = " ", y = "Estágio de Vida", fill = "Tipo de Cliente") +
  theme_minimal()
```

Média dos preços por unidade de chips comprado por cliente, por LIFESTAGE e PREMIUM_CUSTOMER

```{r}
priceMean <- data[, .(Media = mean(TOT_SALES)), by = .(LIFESTAGE, PREMIUM_CUSTOMER)]

ggplot(priceMean, aes(x = Media, y = reorder(LIFESTAGE, Media), fill =
PREMIUM_CUSTOMER)) +
  geom_bar(stat = "identity", position = "dodge") +
  labs(title = "Média de preços por unidade por Segmento",
      x = " ", y = "Estágio de Vida", fill = "Tipo de Cliente") +
  theme_minimal()
```

Vamos checar se a diferença de preço por unidade é estatisticamente diferente dos grupos Mainstream versus Budget e Premium, de Young Singles/Couples e Midage Singles/Couples , utilizando o teste t.

```{r}


#YoungBxM
t.test(data$TOT_SALES ~ data$PREMIUM_CUSTOMER,
                   data = data,
                   subset = (data$LIFESTAGE == "YOUNG SINGLES/COUPLES" &
data$PREMIUM_CUSTOMER %in% c("Mainstream", "Budget"))) #p-value < 2.2e-16


#YoungPxM
```

```
t.test(data$TOT_SALES ~ data$PREMIUM_CUSTOMER,
                   data = data,
                   subset = (data$LIFESTAGE == "YOUNG SINGLES/COUPLES" &
data$PREMIUM_CUSTOMER %in% c("Mainstream", "Premium"))) #p-value < 2.2e-16

#MidBxM
t.test(data$TOT_SALES ~ data$PREMIUM_CUSTOMER,
                   data = data,
                   subset = (data$LIFESTAGE == "MIDAGE SINGLES/COUPLES" &
data$PREMIUM_CUSTOMER %in% c("Mainstream", "Budget"))) #p-value < 2.2e-16

#MidPxM
t.test(data$TOT_SALES ~ data$PREMIUM_CUSTOMER,
                   data = data,
                   subset = (data$LIFESTAGE == "MIDAGE SINGLES/COUPLES" &
data$PREMIUM_CUSTOMER %in% c("Mainstream", "Premium"))) #p-value < 2.2e-16
```

Para um nível de significância igual à 0,05 , rejeitamos a hipótese que as diferença das médias é zero para todos os casos, ou seja, as médias são estatisticamente diferentes em todos os casos.

Vamos focar em segmentos de clientes que mais contribuem nas vendas, para retê-los ou aumentar ainda mais as vendas. Analizaremos o Mainstream e Young Single/Couples. Vamos ver se eles tendem a comprar um tipo de marca específica.

```{r}
PremBrands <- data[, .(N = sum(PROD_QTY)), by = .(PREMIUM_CUSTOMER , BRAND)]
MainBrands <- PremBrands[PREMIUM_CUSTOMER == "Mainstream"]

ggplot(MainBrands, aes(x = N, y = reorder(BRAND, N))) +
  geom_bar(stat = "identity", fill = "pink") +
  labs(title = "Número de compras por Marca da Classe Mainstream" , x = " ", y =
"Marcas")

```